

基本信息

姓名：刘昊晴

出生年月：2003年5月

性别：男

求职意向：AI应用开发工程师

电话：13392786414

邮箱：13392786414@163.com

个人博客：<https://star-nebula.github.io/knowledge>

教育经历

2021~2025 岭南师范学院 人工智能

专业技能

大模型与RAG、多Agent开发：

- 深入理解 Transformer 架构与 Self-Attention 多头注意力机制，掌握 LLM 底层原理，具备 DeepSeek、Qwen 等主流开源大模型的工程调用与落地经验
- 熟悉 LoRA、P-Tuning 等微调方案与 Prompt 工程、Few-shot 提示增强方法，熟练 LangChain 框架，独立设计落地分层 RAG 整套业务系统
- 依托 Function Calling 与 ReAct / CoT 自主推理实现工具调用编排，掌握 MCP、A2A 协议，具备基于协议接入的分布式多智能体系统设计能力，有分层记忆、多级容灾降级与收敛控制落地经验
- 掌握 vLLM 推理引擎，具备企业级部署与 OpenAI / DeepSeek / Qwen 等主流大模型 API 调用经验

NLP 与深度学习：

- 熟悉 PyTorch、Hugging Face Transformers 开发，具备 BERT 微调与模型压缩（量化/蒸馏/剪枝）在文本分类方向的完整落地经验
- 熟悉 CNN、RNN、LSTM、GRU 等经典网络结构，可运用于文本序列建模；掌握数据集划分、数据增强、过拟合抑制等训练优化手段

工程基础与工具：

- 掌握 Milvus 向量检索与索引调优、Redis 多级缓存设计、MySQL 关系数据库开发优化；熟练 FastAPI 搭建高并发 AI 推理服务，可使用 Flask 快速搭建演示原型
- 熟练使用 Python (NumPy / Pandas / Matplotlib) 完成数据清洗、样本处理与指标可视化；掌握 SQL 复杂查询编写与索引调优
- 了解 Docker 容器化打包、镜像管理、资源调度，具备灰度发布、线上服务性能迭代调优实战经验

工作经历

2024.08 ~ 2026.05 | 小络科技 | AI应用开发工程师

在职期间独立负责电商AI算法研发，主导多Agent智能体编排、检索增强生成（RAG）全链路优化、BERT文本分类轻量化等核心模块，覆盖智能选品、智能客服、商品管理三大业务场景，显著提升运营效率与系统响应速度。

项目经历

电商每日精选选品简报系统 2025.10 ~ 2026.05

项目概述：基于LangGraph+DeepSeek设计并实现了一个自动化电商选品与个性化选品简报生成的多Agent智能体系统。系统通过订阅并解析内部RSS新品/热销数据源，结合主Agent编排Selection→Ranking→Briefing三个子Agent，采用ReAct自主推理循环实现潜力商品自动挖掘、智能去重、多因子排序与结构化选品简报生成的全链路自动化，支持运营反馈驱动的偏好学习。

技术栈：Python, LangGraph, DeepSeek (v4-flash), ChromaDB, BGE (bge-small-zh-v1.5), SQLite (WAL), Streamlit, FastMCP, APScheduler, Sentence-Transformers, feedparser

主要职责：

- 多Agent编排架构设计：**基于LangGraph StateGraph设计主Agent八阶段编排流水线（选品理解→规划→路由→执行→观察→反思→推送→策略更新），实现Planner节点LLM自主编排与Router节点动态路由决策，支持类目扩展、阈值放宽、重排序等多策略自动调度。
- ReAct自主推理循环实现：**在主Agent与各子Agent中实现Thought→Action→Observation循环机制，主Agent最多3轮迭代、子Agent最多5轮；设计防死循环检测（连续3次相同路由强制收敛）与硬兜底策略，确保系统稳定收敛。
- 多源RSS采集、两级向量去重与跨批次预过滤：**基于feedparser解析内部新品发布流与热销榜单RSS源，作为选品候选池输入；采集阶段使用bge-small-zh-v1.5对商品标题编码（384维），在ChromaDB中预过滤历史已推荐商品（相似度 ≥ 0.92 直接丢弃）；批内采用两级去重（高阈值自动判重+低阈值保留+中间LLM裁决识别同款不同链接），大幅降低后续阶段冗余计算。
- 多因子加权排序与偏好学习：**构建商品匹配度+新品时效性（指数衰减）+运营偏好（正负分离向量）+商品热度的四维评分模型，设计冷启动/热启动双模式权重切换（反馈 < 3 条以商品匹配度为主， ≥ 3 条运营偏好权重占40%）；基于EMA滑动平均更新运营偏好向量，实现偏好平滑演化。
- 选品简报生成与质量评估：**设计预检-生成-评估闭环，生成前硬编码预检（过滤违规商品、库存为0商品、重复店铺），生成后代码层自动质量评分（完整性 $\times 0.3$ +相关性 $\times 0.4$ +连贯性 $\times 0.3$ ），智能清洗商品描述中的促销无关噪音。
- MCP服务与工具注册体系：**基于FastMCP实现商品信息搜索补充服务（SSE :8100, Bing搜索+BeautifulSoup解析）与推送服务（stdio）；设计13个标准化工具注册表（OpenAI Function Calling Schema），按阶段分组统一分发，支持错误隔离。
- 系统工程与前端可视化：**基于SQLite WAL模式设计11张数据表，ChromaDB管理3个向量集合；APScheduler定时触发选品简报生成；Streamlit构建管理后台（选品目标设置/RSS源管理/反馈记录/执行日志/仪表盘）；实现执行栅栏与子Agent错误隔离机制。

项目成果：

- 自主编排与智能调度：**基于LangGraph实现多Agent八阶段编排流水线，Planner+Router实现LLM动态路由与多策略自动调度，ReAct循环赋予系统自主感知与决策能力，商品池不足时自动扩展关联类目、排序不佳时主动调权重重排。
- 个性化排序与偏好学习：**四因子加权排序配合冷热启动双模式切换，零反馈时基于商品匹配度运行，积累运营反馈后自动切换偏好驱动模式；EMA滑动更新使运营偏好向量平滑演化，避免单次反馈过度扰动。
- 高效去重与信息过滤：**采集阶段向量预过滤实现跨批次去重，批内两级去重兼顾效率与精度（同款不同链接自动合并）；智能清洗确保选品简报纯净可读。
- 全链路自动化闭环：**基于RSS订阅实时感知新品/热销动态，APScheduler定时触发+Streamlit管理后台，从商品挖掘到选品简报推送全链路自动化，运营人员每日人工选品耗时从2小时压缩至10分钟复核，执行过程全程可追溯。

电商智能客服问答系统 2025.02 ~ 2025.08

项目概述：设计并实现了一个面向电商购物场景的垂直领域智能客服RAG问答系统。系统覆盖退换货政策、物流查询、商品参数、比价咨询、活动促销、使用教程、尺码推荐、发票与支付八大客服高频知识域，具备智能意图识别、多轮上下文理解等核心能力，为不同咨询场景提供快速、准确、合规的智能客服解决方案。

技术栈：Python, FastAPI, Milvus, Redis, MySQL, BGE-M3, BGE-Reranker-v2-m3, BERT-wwm, Qwen3:14B, vLLM, Docker, Nginx

主要职责：

- 系统架构设计：**参与设计五层分层架构（意图识别→混合检索→Rerank→LLM生成→安全审核），构建模块化、可扩展的RAG流程，支持高并发与低延迟。
- 多源知识库构建：**整理并清洗平台售后政策文档、商品SKU参数表、物流时效说明、活动规则、常见用户咨询FAQ等多源客服资料，采用智能分块策略构建Milvus向量知识库，累积知识条目1000+，覆盖八大客服核心知识域，并设计父块上下文扩展保持语义完整。
- 意图识别与路由模块：**基于BERT-wwm-base微调意图分类模型，采用三阶段渐进训练（通用→领域→精标），在5000+人工标注的客服咨询数据上实现高精度分类（准确率>95%）；设计四级置信度处理策略（高置信、中等、低置信、无关），准确路由复杂和模糊查询，避免无效检索。
- 双路混合检索与重排序：**实现稠密检索（BGE-M3）+稀疏检索（BM25）双路召回，通过RRF融合与BGE-Reranker-v2-m3二次排序；根据不同意图类型动态调整稠密/稀疏权重（如退换货政策查询侧重精确政策条款匹配），召回相关性显著提升。
- 查询理解优化：**设计口语归一化预处理模块（如“买了多久能退”→“退换货时效 条件”），以及关键词扩展、同义词替换、子查询分解等Query改写策略，有效提升模糊咨询的命中率。
- 个性化Prompt与LLM生成：**构建（意图×场景）二维Prompt模板矩阵，通过分场景温度控制（事实类0，策略类0.3）保证准确性；采用三段式内容安全审核机制确保回答合规。
- 系统性能优化与部署：**设计三级缓存（Redis精确匹配+语义索引）拦截高频问题，降低全链路压力；实现Milvus、MySQL、Redis冷热分层存储，平衡速度与成本；通过vLLM企业级部署Qwen3:14B大模型，保障数据隐私。

项目成果：

- 全领域知识覆盖：**成功搭建电商全品类智能客服问答系统，覆盖退换货政策、物流查询、商品参数、比价咨询、活动促销、使用教程、尺码推荐、发票与支付八大知识域，累计构建知识条目超1000条，所有知识经客服运营专家审核入库，确保专业准确性与权威性。
- 意图识别与混合检索：**基于BERT-wwm-base微调意图分类模型，准确率>95%，配合关键词预判与规则融合路由；采用BGE-M3稠密检索与BM25稀疏检索双路召回，经RRF融合与BGE-Reranker-v2-m3重排序，显著提升检索质量与答案相关性。
- 三级缓存高效应答：**设计L1精确匹配+L2语义匹配+L3全链路三级缓存策略，有效拦截高频重复问题，缓存命中率超60%，端到端响应延迟P50<2s（本地部署），大幅降低全链路计算开销。
- 个性化生成：**构建（意图×场景）二维Prompt模板矩阵，通过分场景温度控制保证回答准确性与合规性，为不同咨询场景提供差异化回答。

商品短文本多级类目分类系统 2024.08 ~ 2024.11

项目概述：设计并实现了一个面向自营电商内部运营场景的轻量化商品分类系统。作为公司商品管理后台的核心功能子集，系统在运营人员上架商品时自动预测商品所属叶子类目，将人工逐条选类目的耗时从平均3分钟/件压缩至秒级自动填充，大幅提升商品入库效率。

技术栈：PyTorch, Transformers, Hugging Face, FastText, BERT, Scikit-learn, Pandas, Jieba

主要职责：

- 端到端项目流程与基线建立：**主导完成了从20万条电商商品数据清洗、分词（Jieba）、统计分析到数据集构建的全流程。率先采用随机森林（TF-IDF特征）作为基线模型，快速达到80.31%的准确率，确立了性能优化基准。
- 模型升级与核心算法优化：**首先引入FastText，采用词向量级别的分词并手动调参，模型在测试集上的精确率与召回率提升至90.21%。随后，针对FastText进行模型优化和数据优化，通过自动化最优参数搜索调优并采用字符级别的分词，最终模型在测试集上的精确率和召回率达到了91.69%。再者选用BERT模型，通过调整学习率、批次大小等超参，在5个epoch内使模型快速收敛，最终在十分类电商商品数据集上将测试准确率显著提升至93.61%，较最优FastText模型提升1.92个百分点。
- 模型压缩与性能优化：**开展模型量化、知识蒸馏、模型剪枝三种压缩方案的实现与测试。通过Torch量化将BERT模型参数精度降低，使模型体积从399MB缩减至149MB，而模型准确率提升至93.97%；以BERT为教师模型、TextCNN为学生模型实现知识蒸馏，将模型体积缩减至8MB，保持89.04%的准确率；基于torch.nn.utils.prune模块实现多种剪枝方式，实现模型稠密连接向稀疏连接的转换，平衡模型体积与性能。
- 模型部署与测试：**基于Flask框架搭建服务端，定义路由、视图函数及模型调用逻辑，启动服务；编写客户端测试代码，通过POST请求实现文本分类接口测试，完成工业级模型落地，确保模型可在线提供短文本分类服务。
- 优化策略设计：**针对数据与模型提出优化思路，包括分析Badcase、通过爬虫/大模型生成扩充数据、采用Focal Loss解决样本不平衡问题；针对模型结构开展超参数调优及Vocab、Encoder、Multi-Head等结构优化，为后期模型性能迭代提供方向。

项目成果：

- 分类性能达标：**BERT模型经量化后测试准确率达93.97%，Precision达0.9402，可精准完成10个核心商品类目（如数码电子、家居日用、服饰鞋包、美妆个护、食品生鲜等）的短文本分类，满足内部商品入库的类目自动预测需求。
- 模型轻量化落地：**通过三种压缩方案实现模型体积大幅缩减，量化后模型体积缩减超三分之二，蒸馏后模型体积仅8MB，兼顾性能与部署效率，适配公司内部服务器资源受限场景的部署需求。
- 全流程落地：**完成从数据预处理、多模型训练、性能优化到Flask服务部署、接口测试的全流程实现，形成可复用的商品短文本分类解决方案，已嵌入公司商品管理后台，运营人员上架商品时系统实时预测类目，人工只需确认而非手动查找。
- 效率提升：**量化后的模型推理速度提升，蒸馏后的TextCNN模型推理时间缩短至1秒内，单件商品类目填充从平均3分钟人工操作压缩至毫秒级自动完成，极大提升运营团队商品入库效率。